

# Ejercicio Regresiones

Inteligencia Artificial

# Pronóstico de Compra de Hardware

Una empresa de tecnología necesita predecir si comprará nuevo equipo de cómputo el próximo mes con base en su histórico.

Si la predicción es incorrecta y no se adquiere el hardware a tiempo, la empresa podría enfrentar interrupciones operativas debido a que sus colaboradores no podrán trabajar.

# Evidencia

Se te proporciona el siguiente conjunto de datos y se te pide aplicar **dos iteraciones de gradiente descendente** para actualizar los parámetros del modelo.

| Años desde la última actualización | Compra de PC |
|------------------------------------|--------------|
| 1                                  | No           |
| 2                                  | No           |
| 3                                  | Sí           |
| 4                                  | Sí           |

¿Qué tipo de Regresión  
entrenar?

# Ejercicio de Regresión Logística

Para ayudar en esta decisión, se necesita elaborar un modelo de **regresión logística** que estima la probabilidad de que la empresa realice una compra.

Es fundamental que el modelo sea preciso, ya que una mala predicción podría resultar en compras innecesarias (gasto excesivo) o en la falta de equipos cuando realmente se necesitan, afectando la operación del negocio (Reducir los falsos negativos – Más vale prevenir que lamentar!).

# Ejercicio de Regresión Logística

Se utilizará **regresión logística** para modelar la probabilidad de compra en función del tiempo desde la última actualización. Para ello, se implementará **dos iteraciones** del algoritmo de descenso de gradiente para actualizar los parámetros  $B_0$  y  $B_1$  y una tasa de aprendizaje de 0.10

- Función sigmoide (probabilidad de que sí se compre la PC):

$$p_i = \frac{1}{1 + e^{-z}}$$

- Ecuación del modelo:

$$P(y = 1|x) = p_i = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}}$$

## Pasos a Seguir

1. Calcular la probabilidad de que  $y$  sea 1 dadas la(s) características, es decir,  $P(y=1 | x)$  para cada dato.
2. Calcular la función de costo  $J(\beta)$ .
3. Actualizar los valores de  $\beta_0$  y  $\beta_1$  usando la regla del descenso de gradiente.
4. Repetir el proceso.

| X | Y |
|---|---|
| 1 | 0 |
| 2 | 0 |
| 3 | 1 |
| 4 | 1 |

Conjunto de Datos

# Iteración 0

- Parámetros iniciales:  $\beta_0^{(0)} = -2.400$ ,  $\beta_1^{(0)} = 0.897$
- Tasa de aprendizaje:  $\alpha = 0.1$

Función para calcular probabilidades:

$$p_i = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}}$$

Calcular el costo:

$$J = -\frac{1}{4} \sum_{i=1}^4 [y_i \ln(P_i) + (1 - y_i) \ln(1 - P_i)]$$



# Primera Iteración

Calculo de probabilidades para cada  $x$ :

- Para  $x=1$ :

$$P_1 = \frac{1}{1 + e^{-(-2.400+0.897 \cdot 1)}} = \frac{1}{1 + e^{(1.503)}} \approx 0.1819 \dots$$

- Para  $x=2$ :

$$P_2 = \frac{1}{1 + e^{-(-2.400+0.897 \cdot 2)}} = \frac{1}{1 + e^{(0.606)}} \approx 0.3529 \dots$$

- Para  $x=3$ :

$$P_3 = \frac{1}{1 + e^{-(-2.400+0.897 \cdot 3)}} = \frac{1}{1 + e^{-(0.291)}} \approx 0.5722 \dots$$

- Para  $x=4$ :

$$P_4 = \frac{1}{1 + e^{-(-2.400+0.897 \cdot 4)}} = \frac{1}{1 + e^{-(1.188)}} \approx 0.7663 \dots$$

# Primera Iteración

Calcular el costo:

$$J = -\frac{1}{4} \sum_{i=1}^4 [y_i \ln(P_i) + (1 - y_i) \ln(1 - P_i)]$$

# Primera Iteración

**Calcular el costo:**

$$\begin{aligned} J &= -\frac{1}{4} [0 \cdot \ln(0.1819) + 0 \cdot \ln(0.3529) + 1 \cdot \ln(0.5722) + 1 \cdot \ln(0.7663) + (1 - 0) \cdot \ln(1 - 0.1819) + (1 - 0) \\ &\quad \cdot \ln(1 - 0.3529) + (1 - 1) \cdot \ln(1 - 0.5722) + (1 - 1) \cdot \ln(1 - 0.7663)] \\ &= -\frac{1}{4} [0 + 0 + (-0.5583) + (-0.2662) + (-0.2008) + (-0.4353) + 0 + 0] \\ &= -\frac{1}{4} [-1.4606] \\ &= \frac{1.4606}{4} \\ &\approx 0.3651 \end{aligned}$$

# Primera Iteración

Fórmula de actualización de los parámetros:

- Para  $\beta_0$ :

$$\beta_0 := \beta_0 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (P_i - y^{(i)})$$

- Para  $\beta_1$ :

$$\beta_1 := \beta_1 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (P_i - y^{(i)}) x^{(i)}$$

# Primera Iteración

$\beta_0$ :

$$\textit{Gradiente} = \frac{1}{4}[0.1819 + 0.3529 - 0.4278 - 0.2337] \approx -0.03167 \dots$$

$\beta_1$ :

$$\textit{Gradiente} = \frac{1}{4}[0.1819 \cdot 1 + 0.3529 \cdot 2 - 0.4278 \cdot 3 - 0.2337 \cdot 4] \approx -0.33245 \dots$$

# Primera Iteración

Actualización de parámetros:

- $\beta_0^{(1)} = -2.400 - 0.1 \cdot (-0.0317) \approx -2.400 + 0.00317 = -2.3968 \dots$
- $\beta_1^{(1)} = 0.897 - 0.1 \cdot (-0.3325) \approx 0.897 + 0.03325 = 0.9302 \dots$

# Segunda Iteración

Nuevos Parámetros:

$$\begin{aligned}\beta_0 &= -2.3968 \\ \beta_1 &= 0.9302\end{aligned}$$

Se sustituyen en la ecuación sigmoide:

$$p_i = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_i)}}$$

# Segunda Iteración

Calculo de probabilidades para cada  $x$ :

- Para  $x=1$ :

$$P_1 = \frac{1}{1 + e^{-(-2.3968+0.9302 \cdot 1)}} = \frac{1}{1 + e^{-(-1.4666)}} \approx 0.1874 \dots$$

- Para  $x=2$ :

$$P_2 = \frac{1}{1 + e^{-(-2.3968+0.9302 \cdot 2)}} = \frac{1}{1 + e^{-(-0.5364)}} \approx 0.3690 \dots$$

- Para  $x=3$ :

$$P_3 = \frac{1}{1 + e^{-(-2.3968+0.9302 \cdot 3)}} = \frac{1}{1 + e^{-(0.3938)}} \approx 0.5972 \dots$$

- Para  $x=4$ :

$$P_4 = \frac{1}{1 + e^{-(-2.3968+0.9302 \cdot 4)}} = \frac{1}{1 + e^{-(1.3248)}} \approx 0.7898 \dots$$



# Segunda Iteración

**Calcular el costo:**

$$\begin{aligned} J &= -\frac{1}{4} [0 \cdot \ln(0.1874) + 0 \cdot \ln(0.3690) + 1 \cdot \ln(0.5972) + 1 \cdot \ln(0.7898) + (1 - 0) \cdot \ln(1 - 0.1874) \\ &\quad + (1 - 0) \cdot \ln(1 - 0.3690) + (1 - 1) \cdot \ln(1 - 0.5972) + (1 - 1) \cdot \ln(1 - 0.7898)] \\ &= -\frac{1}{4} [-1.4194] \\ &= \frac{1.4194}{4} \approx 0.3548 \dots \end{aligned}$$

# Segunda Iteración

Fórmula de actualización de los parámetros:

- Para  $\beta_0$ :

$$\beta_0 := \beta_0 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (P_i - y^{(i)})$$

- Para  $\beta_1$ :

$$\beta_1 := \beta_1 - \alpha \cdot \frac{1}{m} \sum_{i=1}^m (P_i - y^{(i)}) x^{(i)}$$

# Segunda Iteración

$\beta_0$ :

$$\textit{Gradiente} = \frac{1}{4}[0.1874 + 0.3690 - 0.4028 - 0.2102] = -0.0142$$

$\beta_1$ :

$$\textit{Gradiente} = \frac{1}{4}[0.1874 \cdot 1 + 0.3690 \cdot 2 - 0.4028 \cdot 3 - 0.2102 \cdot 4] = -0.28095$$

# Segunda Iteración

Actualización de parámetros:

- $B_0^{(2)} = -2.3968 - 0.1 \cdot (-0.0142) \approx -2.3968 + 0.0014 = -2.3954$
- $B_1^{(2)} = 0.9302 - 0.1 \cdot (-0.2809) \approx 0.9305 + 0.0281 = 0.9586$

## Calculo de probabilidades

Verificamos para los valores de X, usando la ecuación:

$$p_i = \frac{1}{1 + e^{-(-2.395 + 0.958x_i)}}$$

| <b>Xi</b> | <b>Pi(probabilidad de compra)</b> |
|-----------|-----------------------------------|
| 1         | p                                 |
| 2         | p                                 |
| 3         | p                                 |
| 4         | p                                 |

# Umbral de Decisión

## Condición para el Umbral de Decisión en Regresión Logística:

El umbral de decisión ( $\theta$ ) es el valor que determina si un caso se clasifica como clase positiva (1) o negativa (0). La condición general es:

$$\text{Predicción} = \begin{cases} 0, & \text{si } P_i < \theta \\ 1, & \text{si } P_i \geq \theta \end{cases}$$

## Umbral por Defecto ( $\theta=0.5$ ):

Condición:

Si  $P_i \geq 0.5$ , se predice  $y=1$ ; de lo contrario,  $y=0$ .

| <b>Xi</b> | <b>Pi(probabilidad de compra)</b> |
|-----------|-----------------------------------|
| 1         | 0.1919                            |
| 2         | 0.3825                            |
| 3         | 0.6175                            |
| 4         | 0.8080                            |

# Ajuste del Umbral

## Ajuste del Umbral ( $\theta$ ):

El umbral puede modificarse según el contexto del problema:

1. Si es crítico minimizar falsos negativos (ej: detectar fraudes):  
Se elige  $\theta < 0.5$  (ej:  $\theta = 0.3$ ).
2. Si es crítico minimizar falsos positivos (ej: diagnóstico médico):  
Se elige  $\theta > 0.5$  (ej:  $\theta = 0.7$ ).

| <b><math>X_i</math></b> | <b><math>P_i</math>(probabilidad de compra)</b> |
|-------------------------|---|
| 1                       | 0.1919  |
| 2                       | 0.3825  |
| 3                       | 0.6175  |
| 4                       | 0.8080  |

# Predicción

## Ejemplo concreto:

Si el modelo predice que no se necesita equipo ( $P_i < \theta$ ), pero en realidad sí se necesita ( $y=1$ ), la empresa no podrá operar!

Por lo tanto, se elige un umbral bajo  $\theta=0.40$

$$\text{Predicción} = \begin{cases} 0, & \text{si } P_i < 0.40 \\ 1, & \text{si } P_i \geq 0.40 \end{cases}$$

| <b>Xi</b> | <b>Pi(probabilidad de compra)</b> | <b>Predicción</b> |
|-----------|-----------------------------------|-------------------|
| 1         | 0.1919                            | 0                 |
| 2         | 0.3825                            | 0                 |
| 3         | 0.6175                            | 1                 |
| 4         | 0.8080                            | 1                 |