

# Serie 1

$$\cdot \quad U \perp X$$

## Afirmación 1: $U \perp X$

- Camino entre  $U$  y  $X$ :  $U \leftarrow T \rightarrow X$

Este es un Common Cause ( $A \leftarrow B \rightarrow C$ ) con  $B=T$ .

- Si  $T$  no está observado, el Common Cause es activo.
- Si  $T$  está observado, el Common Cause es inactivo.
- Condición: No hay ninguna variable condicional, así que  $T$  no está observado.
- Resultado: El camino es activo, por lo tanto,  $U$  y  $X$  no son independientes .

**Falsa**

$$\cdot \quad U \perp X|T$$

## Afirmación 2: $U \perp X|T$

- Camino entre  $U$  y  $X$ :  $U \leftarrow T \rightarrow X$

Este es un Common Cause ( $A \leftarrow B \rightarrow C$ ) con  $B=T$ .

- Si  $T$  está observado, el Common Cause es inactivo .
- Condición: Aquí,  $T$  está condicionalmente observado.
  - Resultado: El camino es inactivo, por lo tanto,  $U$  y  $X$  son independientes condicionalmente dado  $T$  .

**Verdadera**

$$\cdot \quad V \perp W|Y$$

**Afirmación 3:  $V \perp W|Y$**

- Camino entre  $V$  y  $W$ :  $V \rightarrow Y \leftarrow W$

Este es un Common Effect ( $A \rightarrow B \leftarrow C$ ) con  $B=Y$ .

- Si  $Y$  está observado, el Common Effect es activo.
- Si  $Y$  no está observado, el Common Effect es inactivo.
- Condición: Aquí,  $Y$  está condicionalmente observado.
- Resultado: El camino es activo, por lo tanto,  $V$  y  $W$  no son independientes condicionalmente dado  $Y$ .

**Falsa**

$$\cdot \quad V \perp W|T$$

**Afirmación 4:  $V \perp W|T$**

- Camino entre  $V$  y  $W$ :  $V \rightarrow Y \leftarrow W$


Este es un Common Effect ( $A \rightarrow B \leftarrow C$ ) con  $B=Y$ .

- Si  $Y$  está observado, el Common Effect es activo.
- Si  $Y$  no está observado, el Common Effect es inactivo.
- Condición: Aquí,  $T$  está condicionalmente observado, pero  $Y$  no está observado.
- Resultado: El camino es inactivo, por lo tanto,  $V$  y  $W$  son independientes condicionalmente dado  $T$ .

**Verdadera**

# Serie 2

$P(A D, X)$			
$+d$	$+x$	$+a$	0.9
$+d$	$+x$	$-a$	0.1
$+d$	$-x$	$+a$	0.8
$+d$	$-x$	$-a$	0.2
$-d$	$+x$	$+a$	0.6
$-d$	$+x$	$-a$	0.4
$-d$	$-x$	$+a$	0.1
$-d$	$-x$	$-a$	0.9



$P(D)$	
$+d$	0.1
$-d$	0.9

$P(X D)$		
$+d$	$+x$	0.7
$+d$	$-x$	0.3
$-d$	$+x$	0.8
$-d$	$-x$	0.2

$P(B D)$		
$+d$	$+b$	0.7
$+d$	$-b$	0.3
$-d$	$+b$	0.5
$-d$	$-b$	0.5

## a) $P(+d, +a)$

Variables de Consulta: D, A

Ocultas: X

Evidencia: No hay

Eliminación de Variables: Eliminar X

Tablas a trabajar:

$P(D)$     $P(X|D)$     $P(A|D, X)$

Sabemos según la pregunta D es  $+d$  y A es  $+a$  por tanto podemos reducir las tablas a:

$P(+d)$     $P(X|+d)$     $P(+a|+d, X)$

$$P(+d) = 0.1$$

$P(X|+d)$

D	X	$P(X D)$
$+d$	$+x$	0.7
$+d$	$-x$	0.3

$P(+a|+d, X)$

D	X	A	$P(X D)$
$+d$	$+x$	$+a$	0.9
$+d$	$-x$	$+a$	0.8

Join:  $P(X|+d)*P(+a|+d,X)$

$$(0.7*0.9)+(0.3*0.8)=0.63+0.24=0.87$$

$$\text{Sum(eliminación): } P(+d)*P(+a,X,+d) = 0.1*0.87 = \mathbf{0.087}$$

$$\text{b) } \mathbf{P(+d|+a)} = \frac{P(+d,+a)}{P(+a)}$$

Se obtuvo  $\mathbf{P(+d,+a)}$  del inciso anterior o sea 0.087

$$\mathbf{P(+a)} = \sum P(+a,D) = P(+a,+d)+P(+a,-d)$$

$\mathbf{P(+a,+d)}$  es lo mismo que  $\mathbf{P(+d,+a)}$  o sea 0.087, por tanto solo debemos encontrar  $P(+a,-d)$

$\mathbf{P(+a,-d)} = \sum P(+a,X,-d)$  entonces eliminación de variables, para eliminar X

$$\sum P(+a,X,-d) = P(+a|-d,X) P(X|-d) P(-d)$$

D	X	A	P(X D)
-d	+x	+a	0.6
-d	-x	+a	0.1

D	X	P(X D)
-d	+x	0.8
-d	-x	0.2

$$0.9*(0.6*0.8)+(0.2*0.1)=0.45$$

$$\text{Entonces } P(+d|+a) = \frac{P(+d,+a)}{P(+a)} = \frac{P(+d,+a)}{P(+a,+d)+P(+a,-d)} = \frac{0.087}{0.087+0.45} = \mathbf{0.162}$$

$$\text{c) } \mathbf{P(+d|+b)} = \frac{P(+d,+b)}{P(+b)} = \frac{P(+b|+d) P(+d)}{P(+b)}$$

$P(+b|+d)$  lo conocemos de la tabla  $P(B|D)$  y también  $P(+d)$  de  $P(D)$   
 por tanto solo queda calcular  $P(+b) = \sum P(+b,D) = P(+b,+d) + P(+b,-d)$   
 $P(+b,+d) + P(+b,-d) = P(-d)P(+b|-d) + P(+d)P(+b|+d)$

Según las tablas

$$P(-d) = 0.9$$

$$P(+b|-d) = 0.5$$

$$P(+d) = 0.1$$


$$P(+b|+d) = 0.7$$

$$P(+b) = \sum P(+b,D) = (0.9 \cdot 0.5) + (0.1 \cdot 0.7) = 0.52$$

Sabiendo que  $P(+b|+d) = 0.7$  y  $P(+d) = 0.1$

$$\text{Entonces } P(+d|+b) = \frac{0.7 \cdot 0.1}{0.52} = \mathbf{0.135}$$

## Serie 3



$M$	$F$	$P(L = +l M, F)$
$+m$	$+f$	0.05
$+m$	$-f$	0.01
$-m$	$+f$	0.9
$-m$	$-f$	0.02

Valor de $M$	Símbolo	Probabilidad $P(M)$
"Tiene clase matutina"	$+m$	0.7
"No tiene clase matutina"	$-m$	$1 - 0.7 = \mathbf{0.3}$

Valor de $F$	Símbolo	Probabilidad $P(F)$
"Amigos regresan"	$+f$	0.8
"Amigos no regresan"	$-f$	$1 - 0.8 = \mathbf{0.2}$

### a) Fórmula para la distribución de probabilidad conjunta

La red Bayesiana tiene la siguiente estructura:

- M (clase matutina) y F (amigos regresan) son nodos padres de L (disfrute universitario)
- La distribución de probabilidad conjunta en una red bayesiana se expresa como:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Padres}(X_i))$$

**Respuesta:**

$$P(M, F, L) = P(M) \times P(F) \times P(L \mid M, F)$$

Donde:

- $P(M)$  es la probabilidad marginal de tener clase matutina
- $P(F)$  es la probabilidad marginal de que los amigos regresen
- $P(L|M,F)$  es la probabilidad condicional de disfrutar dado M y F (tabla proporcionada)

### b) Probabilidad de que sus amigos regresen y no tenga clase matutina

Queremos calcular  $P(F=+f, M=-m)$ :

Datos:

- $P(F=+f)=0.8$
- $P(M=+m)=0.7$ , por lo tanto  $P(M=-m)=1-0.7=0.3$

Como M y F son independientes (no tienen padres en común en la red):

$$P(F = +f, M = -m) = P(F = +f) \times P(M = -m) = 0.8 \times 0.3 = 0.24$$

**Respuesta:** La probabilidad es 0.24 o 24%.

**c) Probabilidad de que sus amigos regresen dado que le está gustando el semestre**

Queremos calcular  $P(F=+f|L=+l)$ . Usaremos el teorema de Bayes:

$$P(F = +f | L = +l) = \frac{P(L = +l | F = +f) \times P(F = +f)}{P(L = +l)}$$

**1. Calcular  $P(L=+l | F=+f)$**

Marginalizamos sobre M:

$$\begin{aligned} P(L = +l | F = +f) &= \sum_M P(L = +l | M, F = +f)P(M) \\ &= P(L=+l | M=+m, F=+f)P(M=+m) + P(L=+l | M=-m, F=+f)P(M=-m) \\ &= 0.05 \times 0.7 + 0.9 \times 0.3 \\ &= 0.035 + 0.27 = 0.305 \end{aligned}$$

**2. Calcular  $P(L=+l)P(L=+l)$**

Marginalizamos sobre M y F:

$$\begin{aligned} P(L = +l) &= \sum_{M,F} P(L = +l | M, F)P(M)P(F) \\ &= P(L=+l | M=+m, F=+f)P(M=+m)P(F=+f) + \\ &\quad P(L=+l | M=+m, F=-f)P(M=+m)P(F=-f) + \\ &\quad P(L=+l | M=-m, F=+f)P(M=-m)P(F=+f) + \\ &\quad P(L=+l | M=-m, F=-f)P(M=-m)P(F=-f) \\ &= 0.05 \times 0.7 \times 0.8 + 0.01 \times 0.7 \times 0.2 + 0.9 \times 0.3 \times 0.8 + 0.02 \times 0.3 \times 0.2 \\ &= 0.028 + 0.0014 + 0.216 + 0.0012 \\ &= 0.2466 \end{aligned}$$

**3. Aplicar Bayes**

$$\begin{aligned} P(F = +f | L = +l) &= \frac{0.305 \times 0.8}{0.2466} \\ &= \frac{0.244}{0.2466} \approx 0.9895 \end{aligned}$$

**Respuesta:** La probabilidad es aproximadamente 0.9895 o 98.95%.

# Serie 4

## 1. Calcular los log-odds (z) para cada dato

La fórmula de los log-odds es:

$$z = \beta_0 + \beta_1 \cdot X$$

Donde:

- $\beta_0 = -58.0264$  (intercepto)
- $\beta_1 = 0.0116$  (coeficiente de ingresos)

Aplicamos para cada cliente:

Ingresos (X)	Cálculo de z	Log-odds (z)
2000	$-58.0264 + 0.0116 \cdot 2000$	$-58.0264 + 23.2 = -34.8264$
4000	$-58.0264 + 0.0116 \cdot 4000$	$-58.0264 + 46.4 = -11.6264$
6000	$-58.0264 + 0.0116 \cdot 6000$	$-58.0264 + 69.6 = 11.5736$
8000	$-58.0264 + 0.0116 \cdot 8000$	$-58.0264 + 92.8 = 34.7736$

## 2. Aplicar la función sigmoide para obtener probabilidades

La sigmoide convierte log-odds (z) en probabilidades (P):

$$P = \frac{1}{1 + e^{-z}}$$

Calculamos para cada z:

Ingresos (X)	Log-odds (z)	Cálculo de P	Probabilidad P
2000	-34.8264	$\frac{1}{1 + e^{34.8264}}$	$\approx 0$ (prácticamente 0)



4000	-11.6264	$\frac{1}{1 + e^{11.6264}}$	$\approx 0$ (muy cercano a 0)
6000	11.5736	$\frac{1}{1 + e^{-11.5736}}$	$\approx 1$ (muy cercano a 1)
8000	34.7736	$\frac{1}{1 + e^{-34.7736}}$	$\approx 1$ (prácticamente 1)

**Nota:**

- Si  $z$  es negativo grande,  $P \approx 0$ .
  - Si  $z$  es positivo grande,  $P \approx 1$ .
- 

### 3. Predecir para nuevos valores de $X$

Usamos el mismo proceso para  $X=\{3000,5000,7000\}$ , con umbral 0.5:

Ingresos ( $X$ )	Probabilidad $P$	Predicción
3000	$\approx 0$	0 (no compra)
5000	0.493	0 (no compra)
7000	$\approx 1$	1 (compra)

---

### Interpretación

- El modelo "aprendió" que:
  - Clientes con ingresos **altos** ( $X \geq 6000$ ) tienden a comprar ( $y=1$ ).
  - Clientes con ingresos **bajos** ( $X \leq 5000$ ) no compran ( $y=0$ ).
- El punto de corte está cerca de  $X=5000$ :
  - En  $X=5000$ ,  $P \approx 0.5$ , lo que indica incertidumbre.

# Serie 5

Calcular las métricas clave:

Precisión para spam y Recall para spam. El objetivo es encontrar el modelo que:

- Maximice la precisión para spam (evitar falsos positivos, FP).
- Mantenga un buen recall (capturar la mayoría del spam, TP).

Métricas:

- **Precisión (Precision):** Cuando el modelo predice la clase positiva, ¿cuántas veces acierta? =  $TP / (TP + FP)$
- **Sensibilidad (Recall):** Proporción de ejemplos positivos correctamente clasificados.
  - $sensibilidad = TP / (TP + FN)$

Modelo	Precisión (spam)	Recall (spam)	Resultado
A	58.3%	70%	<b>Mejor equilibrio:</b> Precisión aceptable y recall decente.
B	31.0%	90%	<b>Más spam detectado (TP), pero muchos FP (200).</b>
C	80%	20%	Alta precisión, pero recall muy bajo (pierde 80% del spam).
D	14.3%	50%	El peor: baja precisión y recall mediocre.

- a): El Modelo A es el mejor equilibrado.

Para resolver la pregunta b), en la tabla anterior vemos que el modelo B es la respuesta, porque prioriza la cantidad de spam detectado (recall alto), incluso si eso implica clasificar incorrectamente muchos no-spam como spam (FP altos), o de otra manera:

Modelo	TP (spam detectado)	FP (errores graves)	Recall	Precisión
A	70	50	70%	58.3%
B	<b>90 (más alto)</b>	<b>200 (alto)</b>	90%	31.0%
C	20 (bajo)	5 (más bajo)	20%	80%
D	50	300 (más alto)	50%	14.3%

- b): El Modelo B detecta más spam (TP alto) pero con muchos errores (FP alto).

**Nota:** Naive Bayes asume independencia entre características, lo que puede explicar los altos FP en algunos modelos (ej. B).